

零分布校准的不变滞后图：鲁棒且可解释的能源预测

蔡文傑

厦门大学

19020232202343@stu.xmu.edu.cn

摘要

稀疏滞后图可使能源预测模型更紧凑、更易解释，但边选择会受到自相关、运行状态变化和正则化设定的影响。较高的 bootstrap 入选频率并不说明一条边比保持自相关结构的零变量更稳定。本文提出零分布校准的不变滞后图 (NCILG)，将时间顺序环境、移动块稳定性选择、循环移位负对照、Wilson 置信下界、系数符号一致性，以及全特征与图约束残差预测器的凸组合用于保守边筛选和预测。结构性结论只在 100 个已知图系统上检验，模拟覆盖线性高斯、非线性重尾、机制切换和弱边四种条件。与 Lasso-VAR、PCMCI、PCMCI+、VAR-LiNGAM 及普通稳定性选择相比，NCILG 获得最高综合 F1 (0.940)、1.000 精确率、零误选边和 1.09 平均结构 Hamming 距离；弱边场景 F1 为 0.795，非线性重尾场景为 0.994。在 UCI Appliances Energy Prediction 上，严格零阈值将 112 维设计压缩至 16 维，图约束 HistGradientBoosting 在 1、6、24 小时取得 42.43、47.34、46.52 的 MAE。在四年家庭用电数据上，图将 Ridge 设计从 39 维压缩至 24 维，平均 MAE 变化不足 1%，但在若干预测跨度上，非线性模型仍然更强。因此，本文刻画的是鲁棒性与可解释性的权衡，而不是普遍预测最优或从观测数据直接识别因果。

1 引言

能源预测通常同时使用自回归负荷、天气、日历变量和大量滞后测量。高维设计增强了灵活性，却难以说明哪些信号在不同时间状态下持续有效。稀疏滞后回归提供了透明替代方案，但单次 Lasso 拟合可能随时间窗口、正则强度和运行状态显著变化。稳定性选择能够降低抽样敏感性 [9]，但固定阈值在自相关时间序列中难以解释；完全随机置换又会破坏时间结构，造成过于容易的零假设。

预测与因果的区分同样关键。Granger 准则关注历史变量能否改善预测 [4]；PCMCI 和 PCMCI+ 处理条件滞后及同时关系 [12, 11]，VAR-LiNGAM 利用非高斯性识别结构向量自回归 [6]。但观测滞后边不自动等价于干预有效的因果关系。不变预测只有在环境与机制假设成立时，才提供稳定性到因果性的理论联系 [10]，普通家庭用电量本身不足以确立这些假设。

NCILG 将训练期切分为多个时间顺序环境，在每个环境内用移动块 bootstrap 保持局部序列依赖；对每个真实变量生成循环移位副本作为负对照，使边缘分布和近似自相关保持不变，同时破坏变量间原有时序对齐。边得分综合入选概率置信下界、系数符号一致性和跨环境低分位数，最终阈值由相应零得分确定。稳定父节点驱动残差预测器，并在过去验证窗上依据均值和尾部误差选择与全特征模型的凸组合，以降低稀疏图设错成本。本文贡献包括：自相关感知的负对照校准、惩罚状态特异和符号不稳关系的跨环境不变得分、带鲁棒校准混合的图约束残差预测，以及已知真值图恢复与两个公开电力数据预测的分离验证。真实数据图仅表示稳定预测性滞后结构，不表示已识别因果效应。

2 相关工作

Lasso 广泛用于稀疏自回归和 Granger 筛选 [13]。稳定性选择通过反复扰动样本保留高频变量 [9]；时间序列不能独立重采样，移动块 bootstrap 用于保存局部平稳依赖 [7]。不变因果预测检验条件机制是否跨环境稳定 [10]，本文只借用不变性思想，并不继承其识别定理。负对照可揭示残余偏差 [8]，本文将其改造为循环移位时间序列。预测方面同时加入持续性、线性回归、树模型和神经序列模型；DLinear 表明简单时序线性模型在长跨度基准上

也可能很强 [15]。图恢复则在相同观测和最大滞后下比较 Lasso-VAR、PCMCI、PCMCI+ 及 VAR-LiNGAM, 避免弱基线造成虚假优势。

3 方法

3.1 时间顺序环境中的滞后回归

设 $x_t \in \mathbb{R}^p$, 正滞后集合为 $\mathcal{L}$ 。对目标 j , 基础选择器拟合

$$\hat{\beta}_j = \arg \min_{\beta} \frac{1}{2n} \left\| x_{j,t} - \sum_{\ell \in \mathcal{L}} \beta_{j,\ell}^\top x_{t-\ell} \right\|_2^2 + \lambda \|\beta\|_1. \quad (1)$$

公式出处与作用。式(1)是 Lasso 目标函数在多变量正滞后设计上的直接写法, 来源为 Tibshirani 的 Lasso 定义 [13]。平方残差项度量拟合误差, ℓ_1 惩罚使一部分系数精确为零, 因此非零系数可以作为候选滞后边。

训练序列被划分为 E 个连续环境; 在环境 e 内, B 个移动块 bootstrap 样本产生边入选指示 $I_{b,e,i \rightarrow j,\ell}$ 和系数符号。令 $k_{e,i \rightarrow j,\ell} = \sum_b I_{b,e,i \rightarrow j,\ell}$, Wilson 置信下界为

$$L_e = \frac{\hat{p} + z^2/(2B) - z\sqrt{\hat{p}(1-\hat{p})/B + z^2/(4B^2)}}{1 + z^2/B}, \quad (2)$$

其中 $\hat{p} = k/B$ 。公式出处与作用。这是二项入选比例的 Wilson 区间下界 [14]: 先由 k 次入选和 B 次重采样得到 $\hat{p}$, 再取其保守下界 L_e , 避免少量偶然入选被当作高稳定性。

环境内边得分定义为

$$S_{e,i \rightarrow j,\ell} = L_e \left| B^{-1} \sum_b \text{sign}(\hat{\beta}_{b,e,i \rightarrow j,\ell}) \right|, \quad (3)$$

本文定义与简要推导。该式不是直接移植的既有统计量, 而是本文将两个证据相乘的设计: L_e 衡量“出现得是否足够稳定”; 绝对平均符号位于 $[0, 1]$, 当符号一致时为 1, 正负抵消时趋于 0。两者相乘后, 只有频繁出现且方向一致的边才获得高分。第二项因此抑制虽频繁非零但符号反复变化的系数。

3.2 保持自相关的零分布校准

对每个观测变量执行大于两个 bootstrap 块长度的循环移位, 构造与原序列边缘分布和大部分序列内自相关相同、但与其他变量错位的负对照。真实和零滞后预测量进入同一次 Lasso 拟合, 面对相同目标、惩罚和重采样路径。不变得分取跨环境低分位数

$$S_{i \rightarrow j,\ell}^{\text{inv}} = Q_{0.25}(\{S_{e,i \rightarrow j,\ell}\}_{e=1}^E). \quad (4)$$

本文定义与简要推导。此式将同一候选边在 E 个环境中的得分排序后取 25% 分位数; 它等价于要求至少约四分之三的环境不能给出过低支持。选择低分位数而不是均值, 是为了让只在局部状态有效的关系受到惩罚。该不变性聚合借鉴跨环境稳定性思想 [10], 但本式及其阈值规则是本文的预测性筛选设计, 不是因果识别定理。

令 $\mathcal{N}$ 为移位对照得分集合, 阈值取经验高分位数 $q_{1-\alpha}(\mathcal{N})$ 。若零得分与非因果得分可交换, 秩构造能为新零得分提供有限样本校准; 但时间可交换性只是近似成立, 因此本文报告实际对照超阈率, 并将其称为校准而非严格的错误发现率控制。

3.3 图约束残差预测

对跨度 h , 持续性预测为 $\tilde{y}_{t+h} = y_t$ 。全模型和图模型分别利用全部滞后量, 或所选父节点加目标自身滞后和日历特征, 预测残差 $r_{t+h} = y_{t+h} - y_t$ 。记两种预测为 $\hat{y}^F$ 和 $\hat{y}^G$, 过去验证窗选择

$$\hat{w} = \arg \min_{w \in [0,1]} |y - [(1-w)\hat{y}^F + w\hat{y}^G]| + \gamma Q_{0.90}(|y - [(1-w)\hat{y}^F + w\hat{y}^G]|). \quad (5)$$

算法 1 零分布校准的不变滞后图**Require:** 多变量训练序列、滞后集合 $\mathcal{L}$ 、环境数 E

```

1: for 每个时间顺序环境 do
2:   构造循环移位负对照
3:   for  $b = 1, \dots, B$  do
4:     抽取移动块并拟合稀疏滞后模型
5:     记录边入选情况和系数符号
6:   end for
7:   计算 Wilson 下界得分
8: end for
9: 用式(4)聚合真实边得分
10: 根据环境级零得分校准阈值
11: 拟合全特征与图约束残差预测器
12: 在过去验证窗上选择鲁棒凸组合

```



图 1: NCILG 将图校准与预测器拟合分离：真实数据边解释为稳定预测性滞后关系。

本文定义与简要推导。该目标把候选组合的平均绝对误差与 90% 分位绝对误差相加：前者选择典型表现较好的权重，后者惩罚少数严重误差。 $w \in [0, 1]$ 使部署预测保持为全特征预测与图约束预测的凸组合；因此它是对图可能漏边的验证期风险保护，而非外部文献给出的分布无关保证。

部署输出为 $(1 - \hat{w})\hat{y}^F + \hat{w}\hat{y}^G$ 。该安全混合是基于验证风险的保护，不是分布无关的测试期保证。

4 实验设计

4.1 已知真值模拟

生成 100 个独立随机种子的 8 变量系统，每种场景 25 个。所有系统包含滞后 1 与 2 上的不变边和 4 个时间顺序状态，四种场景依次为线性高斯噪声、Student- t 创新的非线性动力学、机制强度随状态变化以及弱不变边。每个系统另含只在一个状态中出现且不属于不变真值的边，并保留 3,500 个观测。NCILG 与普通汇总稳定性选择、Lasso-VAR、PCMCI、PCMCI+ 和 VAR-LiNGAM 使用相同最大滞后 2；所有系统共用固定超参数，不使用真值边数或测试标签调参。指标为精确率、召回率、F1、结构 Hamming 距离（SHD）和误选边数。该设计遵循因果发现评价应使用已知图而非仅凭真实数据视觉合理性的原则 [3]。

4.2 真实能源数据与实现

UCI Appliances Energy Prediction 包含低能耗住宅的 19,735 条十分钟观测，含电器需求、室内环境、天气和两个显式随机变量 [2, 1]；随机变量与循环移位共同提供负对照，预测跨度为 1、6、24 小时。UCI Individual Household Electric Power Consumption 包含约四年的分钟级数据 [5]，聚合为 34,190 条完整小时观测，变量包括有功/无功功率、电压、电流和三个分表负荷。两个数据集均使用五个扩展滚动起点，比较持续性、全特征 Ridge、全特征 HistGradientBoosting、图约束 Ridge/HistGradientBoosting、DLinear 和两层 GRU。神经模型分别使用 24 小时和 7 天上下文，所有预处理、超参数、早停及混合权重只使用当前滚动起点之前的数据。

表 1: 100 个已知真值系统上的图恢复结果（每种场景 25 个）。

方法	精确率	召回率	F1	SHD	误选边
Lasso-VAR	0.881	0.511	0.600	5.49	0.11
PCMCI	0.729	0.999	0.842	4.16	4.15
PCMCI+	0.662	1.000	0.795	5.73	5.73
VAR-LiNGAM	0.786	0.996	0.878	3.03	2.99
普通稳定性选择	0.824	0.997	0.899	2.61	2.58
NCILG	1.000	0.901	0.940	1.09	0.00




图 2: 四种生成机制上的已知真值图恢复。误差线为系统间标准差；零校准移除状态特异误报，代价是在弱不变边下召回下降。

真实图估计使用 4 个时间环境、每个环境 36 次移动块重采样。Appliances 滞后为 (1, 3, 6) 个十分钟步, Lasso 惩罚 0.018、块长 144; 家庭数据滞后为 1、6、24 小时, 惩罚 0.014、块长 24 小时。真实部署采用 95% Wilson 下界和 99.5% 零分位数。模拟基准采用 24 次重采样、80% 下界 ($z = 1.28$) 和 99% 零分位数, 在全部 100 个系统运行前固定, 以减轻弱边漏选。这是两个预先声明的运行点, 而非逐场景调参。

5 结果

5.1 图恢复

表1汇总 100 个系统。NCILG 的平均 F1 最高, 精确率为 1.000 且没有误选边。PCMCI、PCMCI+ 和 VAR-LiNGAM 召回率接近 1, 但每个系统平均保留 3 到 6 条状态特异边; Lasso-VAR 较保守, 却漏掉约一半不变图。NCILG 在四种场景的 F1 依次为 0.989、0.994、0.981 和 0.795, 剩余错误集中在刻意设置的弱边场景, 清楚体现了保守筛选的代价。

5.2 电器能耗预测

在 Appliances 数据上, 严格零阈值保留十分钟照明边, 以及目标自身稳定的十分钟和 60 分钟滞后。预测设计加上日历项后从 112 维降至 16 维, 不使用按排名填充特征。表2显示, 图约束 Ridge 在全部跨度上优于全 Ridge; 图约束 HistGradientBoosting 在 1、6、24 小时均最优, MAE 为 42.43、47.34 和 46.52, 并且每个跨度在五个滚动起点上都优于全 Ridge。安全线性混合为 43.10、48.30 和 47.42。使用全部输入的 DLinear 与 GRU 均未超过严格图预测器。




图 3: 严格阈值下的 Appliances 滞后图。节点按时间展开，边标签为不变得分；随机对照均低于阈值。

表 2: 真实能源数据的滚动起点 MAE，越低越好。

数据集	方法	特征数	1 小时	6 小时	24 小时
Appliances	持续性	0	49.02	68.41	52.28
	全 Ridge	112	47.92	53.99	53.24
	图 Ridge	16	43.65	49.17	46.75
	NCILG 安全混合	16	43.10	48.30	47.42
	图 HistGB	16	42.43	47.34	46.52
家庭用电	持续性	0	0.380	0.793	0.541
	全 Ridge	39	0.371	0.527	0.475
	图 Ridge	24	0.376	0.540	0.480
	NCILG 安全混合	24	0.370	0.529	0.477

5.3 长时间家庭用电预测

家庭图保留电压、分表 1、分表 2 及目标自身滞后和日历项。安全混合相对全 Ridge 在三个跨度的 MAE 变化为 -0.33% 、 $+0.51\%$ 和 $+0.40\%$ ，同时减少 38% 特征。全 HistGradientBoosting 在 1 小时 (0.308) 和 24 小时 (0.442) 更好，GRU 在 6 小时 (0.451) 最强。因此，NCILG 不声称不受约束预测最优，其价值在于得到跨时间状态持续存在输入的紧凑线性预测器。

6 讨论

扩展模拟基准隔离了跨分布状态不变性的作用。汇总稳定性和现代时序发现方法会接纳只在部分序列中真实可预测、但在其他状态缺失的边；跨环境低分位数在保持综合 F1 的同时拒绝这些边，负对照则使阈值由数据决定。弱边是例外：完美精确率以较低召回为代价。若应用优先发现而非筛查，应采用较宽松运行点或报告排序图。

真实数据中，当全设计包含大量相关温湿度滞后时，图约束最有价值；严格 Appliances 图虽然极稀疏，却同时支持线性和非线性预测。较小的家庭系统冗余较少，压缩几乎不带来精度增益，也没有一种架构在两个数据

表 3: 神经预测基线的五滚动起点 MAE。

数据集	方法	1 小时	6 小时	24 小时
Appliances	DLinear	51.15	52.93	52.42
	GRU	46.90	48.84	48.66
家庭用电	DLinear	0.431	0.459	0.481
	GRU	0.425	0.451	0.463




图 4: 五滚动起点时间顺序预测。图约束改善高维电器能耗问题，而长时间家庭序列仍由不受限非线性模型领先。

集上全面占优。

局限性包括：循环移位只近似满足零可交换性，共享强季节性可能使任何偏移都无效；家庭数据中离散选择得分产生并列，9.2% 零得分达到或超过名义 99.5 分位阈值，说明名义分位数不等于严格有限样本误选控制；时间分段属于观测环境而非随机干预，瞬时效应、潜在混杂、聚合和反馈均未解决。因此，真实边只称为预测性滞后关系，结构因果用语仅用于已知真值模拟。

7 结论

NCILG 结合保持自相关的负对照、环境不变性和鲁棒预测混合。在 100 个已知图系统上，它以零误选边获得高于四种成熟滞后发现基线的综合 F1，并明确暴露弱边召回限制；在电器能耗数据上改善稀疏残差预测；在较长家庭数据上以更少特征保持全 Ridge 精度，但未超过全非线性模型。其适用范围是面向能源预测的鲁棒、可解释滞后筛选，而非仅凭观测数据完成因果识别。

数据与代码可用性

两个真实数据集均可从 UCI Machine Learning Repository 公开获取并采用 CC BY 4.0 许可。脚本保存图得分、零阈值、所选父节点、滚动起点指标、随机种子和全部消融结果。




图 5: 特征压缩与 Ridge MAE 权衡。虚线下方表示用更少滞后量同时改善精度，虚线上方量化可解释性的代价。

参考文献

- [1] Luis Candanedo. Appliances energy prediction, 2017.
- [2] Luis M. Candanedo, Véronique Feldheim, and Dominique Deramaix. Data driven prediction models of energy use of appliances in a low-energy house. *Energy and Buildings*, 140:81–97, 2017.
- [3] Yuxiao Cheng, Ziqian Wang, Tingxiong Xiao, Qin Zhong, Jinli Suo, and Kunlun He. Causalttime: Realistically generated time-series for benchmarking of causal discovery. In *International Conference on Learning Representations*, 2024.
- [4] Clive W. J. Granger. Investigating causal relations by econometric models and cross-spectral methods. *Econometrica*, 37(3):424–438, 1969.
- [5] Georges Hebrail and Alice Berard. Individual household electric power consumption, 2006.
- [6] Aapo Hyvärinen, Kun Zhang, Shohei Shimizu, and Patrik O. Hoyer. Estimation of a structural vector autoregression model using non-gaussianity. *Journal of Machine Learning Research*, 11(56):1709–1731, 2010.
- [7] Hans R. Künsch. The jackknife and the bootstrap for general stationary observations. *The Annals of Statistics*, 17(3):1217–1241, 1989.
- [8] Marc Lipsitch, Eric Tchetgen Tchetgen, and Ted Cohen. Negative controls: A tool for detecting confounding and bias in observational studies. *Epidemiology*, 21(3):383–388, 2010.
- [9] Nicolai Meinshausen and Peter Bühlmann. Stability selection. *Journal of the Royal Statistical Society: Series B*, 72(4):417–473, 2010.
- [10] Jonas Peters, Peter Bühlmann, and Nicolai Meinshausen. Causal inference by using invariant prediction: Identification and confidence intervals. *Journal of the Royal Statistical Society: Series B*, 78(5):947–1012, 2016.

- [11] Jakob Runge. Discovering contemporaneous and lagged causal relations in autocorrelated nonlinear time series datasets. In *Proceedings of the 36th Conference on Uncertainty in Artificial Intelligence*, volume 124 of *Proceedings of Machine Learning Research*, pages 1388–1397, 2020.
- [12] Jakob Runge, Peer Nowack, Marlene Kretschmer, Seth Flaxman, and Dino Sejdinovic. Detecting and quantifying causal associations in large nonlinear time series datasets. *Science Advances*, 5(11):eaau4996, 2019.
- [13] Robert Tibshirani. Regression shrinkage and selection via the lasso. *Journal of the Royal Statistical Society: Series B*, 58(1):267–288, 1996.
- [14] Edwin B. Wilson. Probable inference, the law of succession, and statistical inference. *Journal of the American Statistical Association*, 22(158):209–212, 1927.
- [15] Ailing Zeng, Muxi Chen, Lei Zhang, and Qiang Xu. Are transformers effective for time series forecasting? In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 37, pages 11121–11128, 2023.